



Universitat  
de les Illes Balears

Jornadas de Análisis de Datos Masivos en Empresa

# Big Data: Algoritmos, tecnología y aplicaciones

José Manuel Benítez Sánchez

Dept. Ciencias de la Computación e I.A.

Universidad de Granada



# Contenido

- Datos
- Big Data
- Algoritmos
- Paradigma MapReduce
- Tecnologías para Big Data
- Aplicaciones



# Big Data en los medios de comunicación

**EL MUNDO**  
Líder mundial en español | Miércoles 04/09/2013. Act.

INTERNET | Campus Party Europa 2011  
**'Es la década de ahí vendrá la re**



**EL PAÍS**

**ECONOMÍA**

ECONOMÍA EMPRESAS MERCADOS BOL

## El maná de los datos

- La conversión de datos en información útil para millones de dólares en 2015. La herramienta 'I

SUSANA BLÁZQUEZ | Madrid | 29 SEP 2013 - 01:00

Archivado en: Citigroup Cap Gemini Sogeti S/ IBM Telefónica Aplicaciones informáticas Tecnol



<http://www.elmundo.es/elmundo>

**EL PAÍS**

**ECONOMÍA**

ECONOMÍA EMPRESAS MERCADOS BOLSA MIS AHORROS VIVIENDA TECNOLOGÍA OP

EMPRENDEDORES »

## El Big Data echa una mano al campo

- Una empresa española recoge miles de datos para predecir las cosechas

MARÍA FERNÁNDEZ | 30 NOV 2014 - 00:00 CET

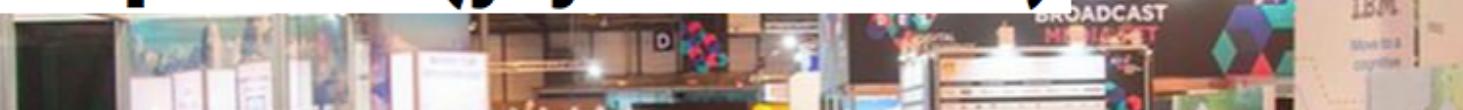
Archivado en: Bases datos Emprendedores Aplicaciones informáticas Empresas Programas informáticos Economía Informática Industria



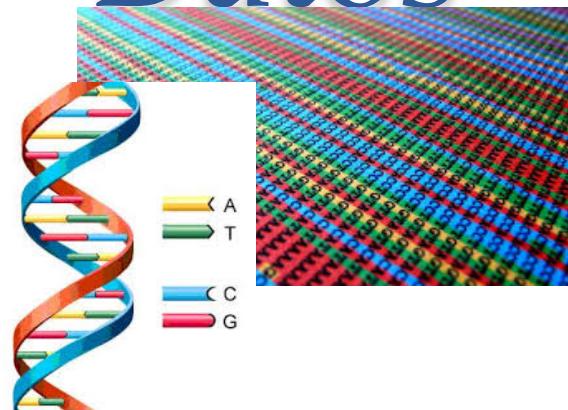
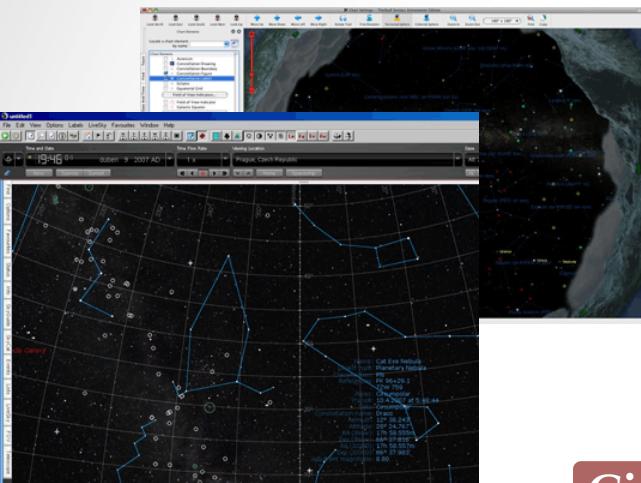
•

**A ESTA HORA** Las siete noticias necesarias antes de desconectar[INICIO](#) | [TECNOLOGÍA](#) | TODOS HABLAN DE BIG DATA PERO NADIE SABE LO QUE ES (Y YA ES HORA)

# Todos hablan de big data pero nadie sabe lo que es (y ya es hora)



# Datos



Ciencia

Medicina

Ciencias Sociales y Humanidades

Negocio, Comercio e Industria

Entretenimiento y Ocio



# Economía basada en los datos

Los datos están en el centro de la sociedad y economía del conocimiento

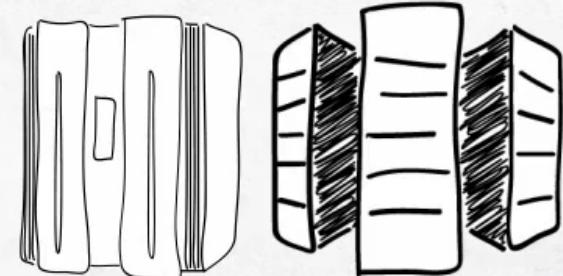
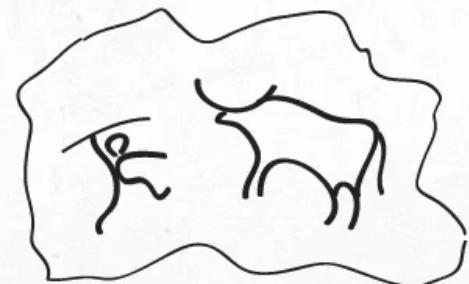
Towards a thriving data-driven economy  
(Hacia una próspera economía basada en datos)

Communication SWD 214  
European Comission, July 2014

<https://ec.europa.eu/digital-agenda/en/news/communication-data-driven-economy>

# Crecimiento explosivo

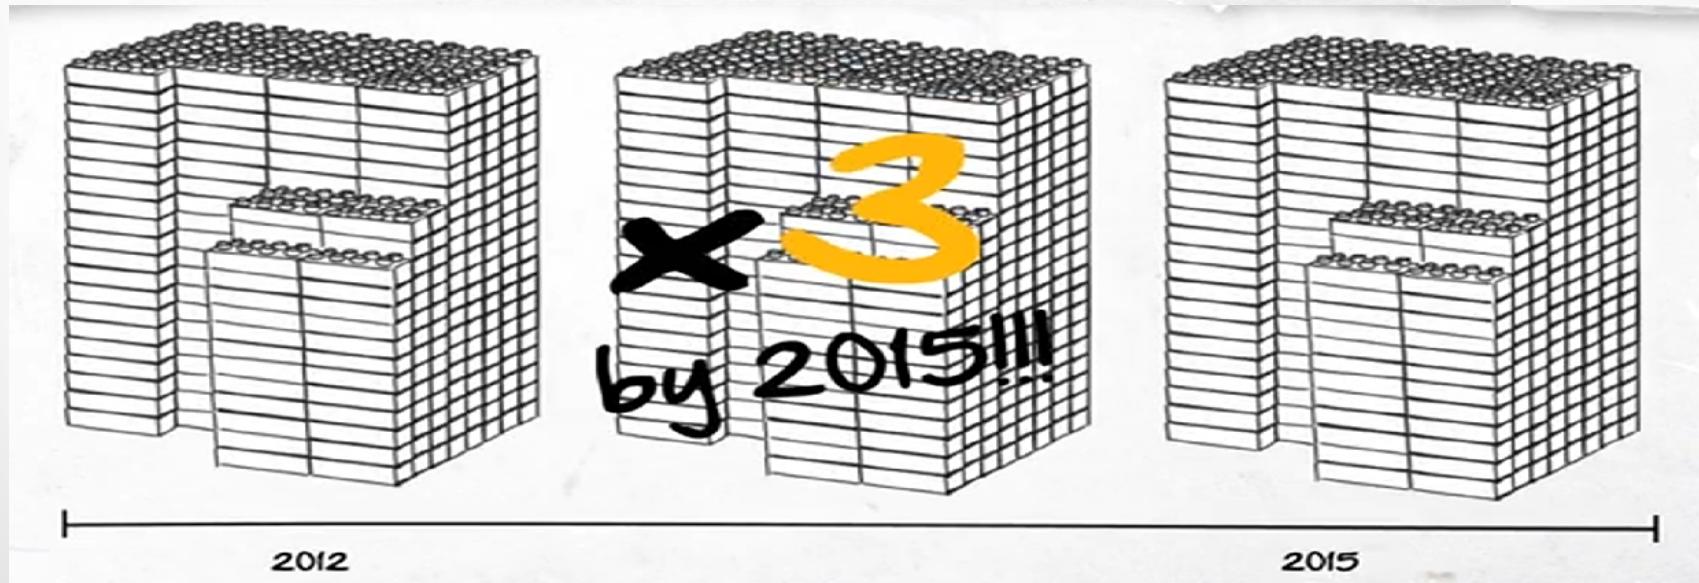
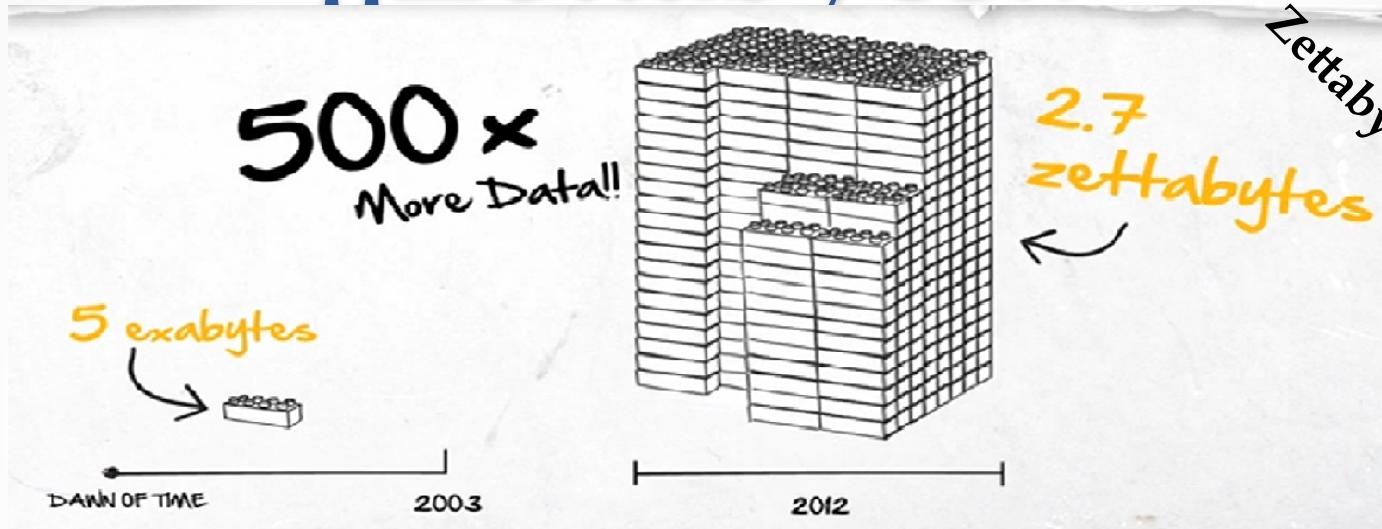
5 exabytes



DAWN OF TIME

2003

# !!Zettabytes!!



# Unidades de información

Kilobyte =  $10^3$  = 1.000

Megabyte =  $10^6$  = 1.000.000

Gigabyte =  $10^9$  = 1.000.000.000

**Terabyte** =  $10^{12}$  = 1.000.000.000.000

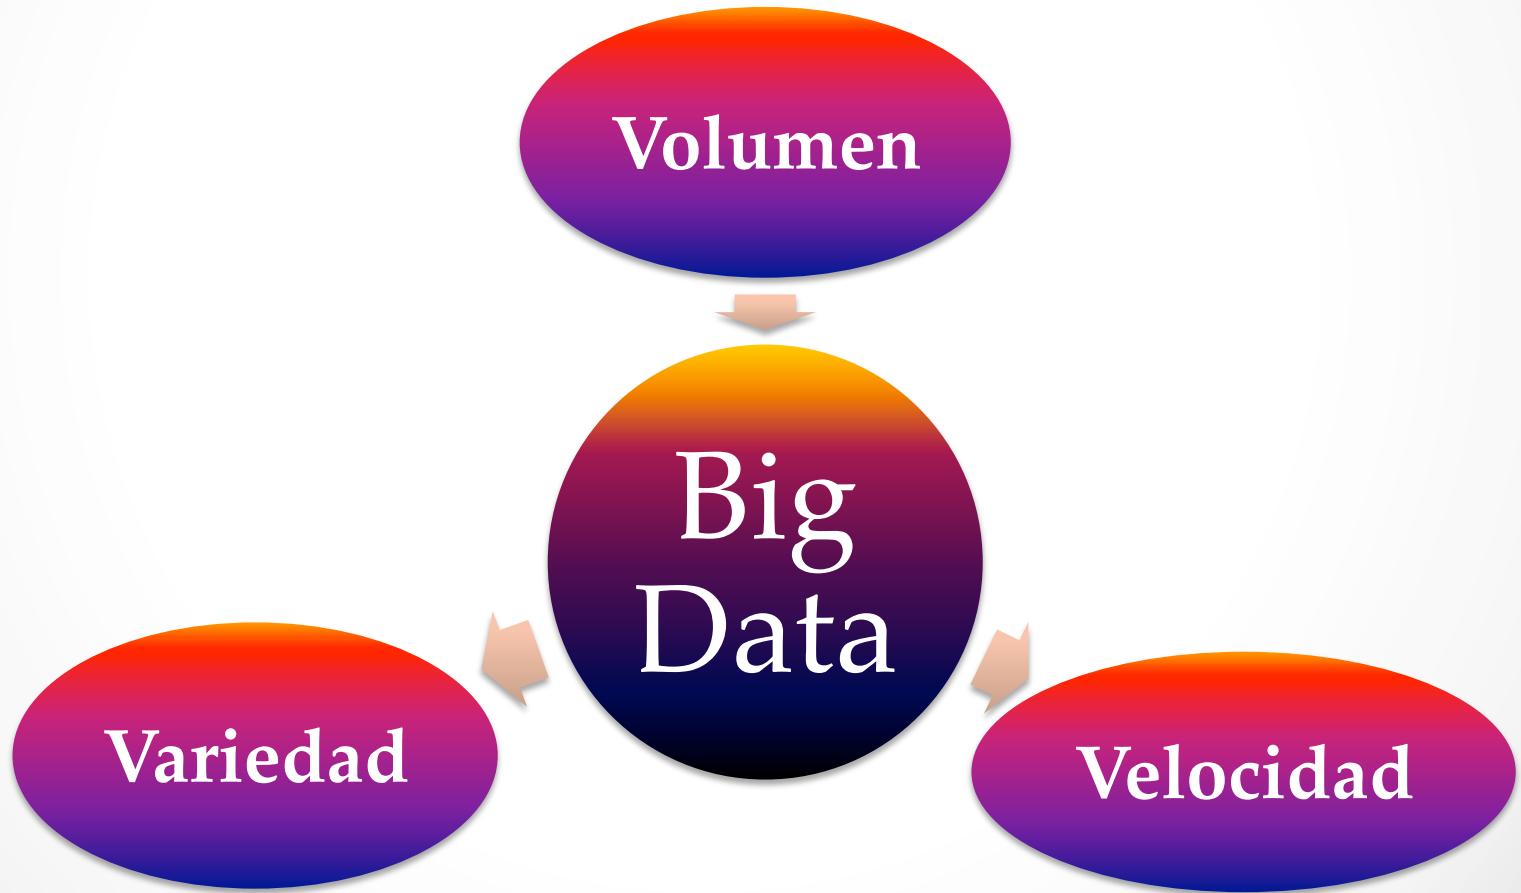
**Petabyte** =  $10^{15}$  = 1.000.000.000.000.000

**Exabyte** =  $10^{18}$  = 1.000.000.000.000.000.000

**Zettabyte** =  $10^{21}$

**Yottabyte** =  $10^{24}$

# Dimensiones V



# ¿Qué es Big Data?

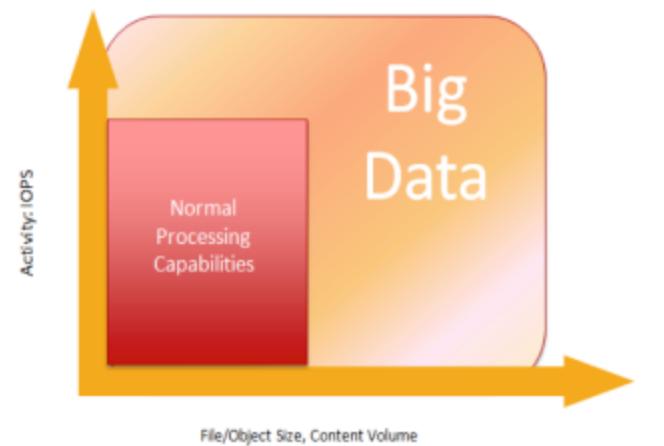
No hay una definición estándar



**Big data** es una colección de datos grande, complejos, **muy difícil de procesar a través de herramientas de gestión y procesamiento de datos tradicionales**



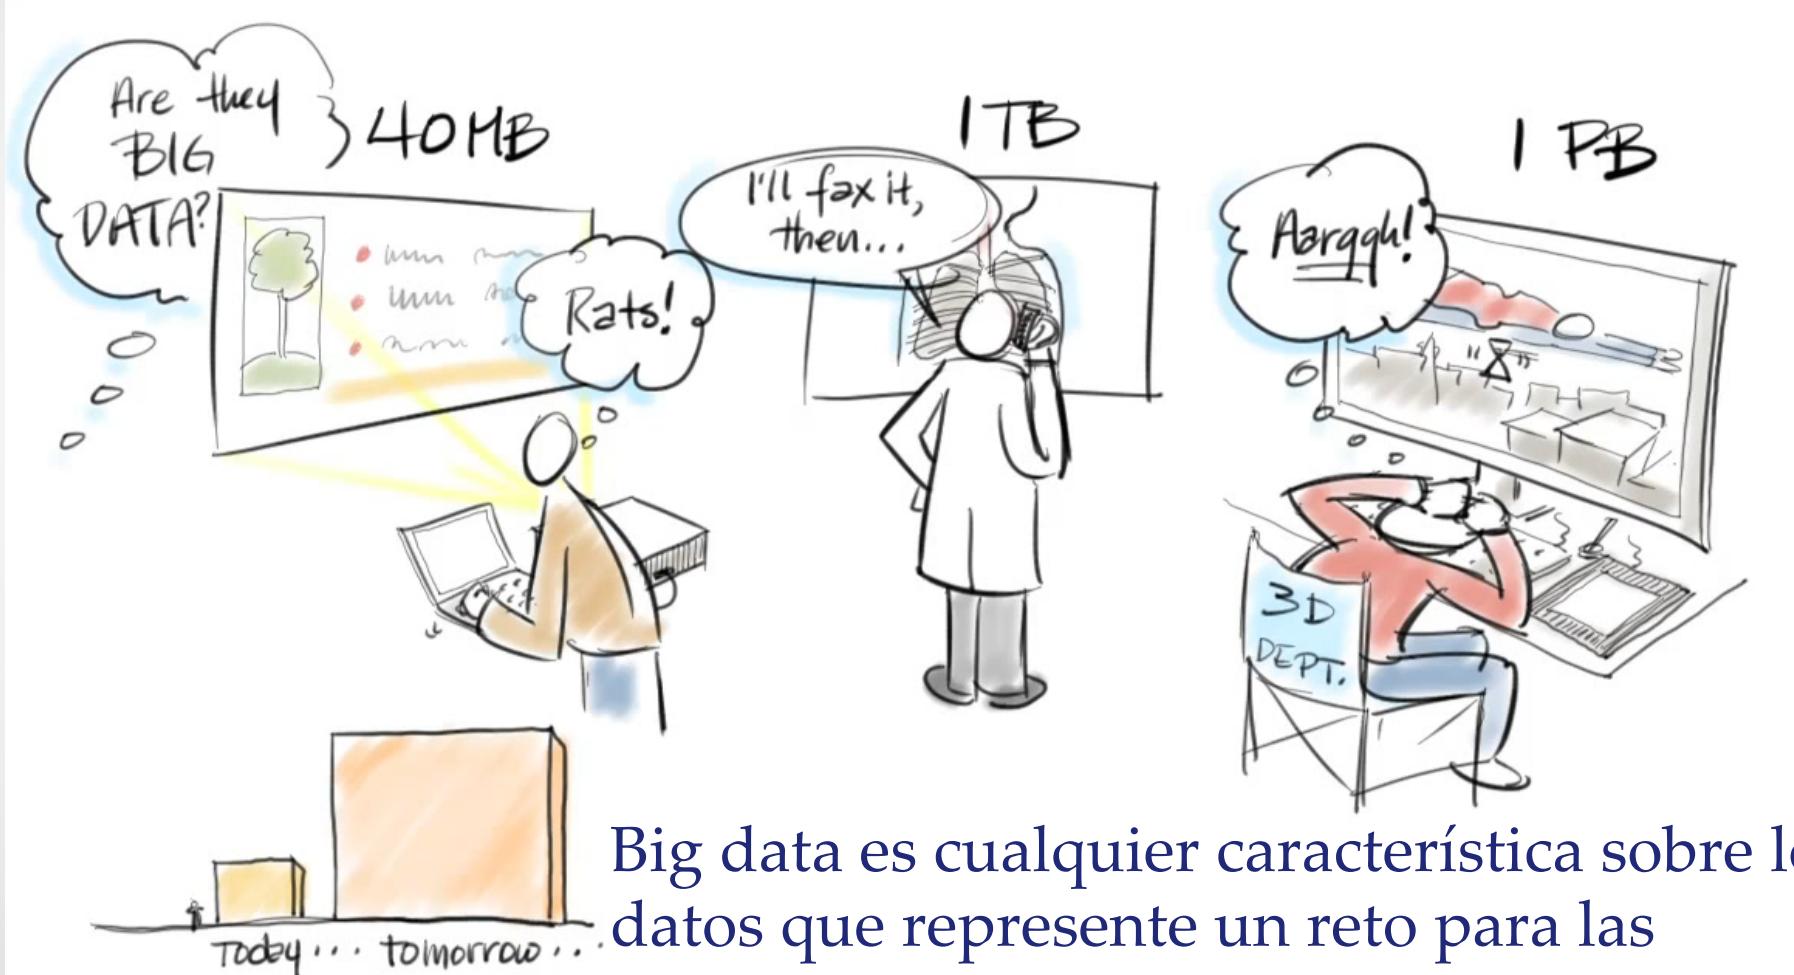
“*Big Data*” son datos cuyo volumen, diversidad y complejidad requieren nueva arquitectura, técnicas, algoritmos y análisis para gestionar y extraer valor y conocimiento oculto en ellos ...



# Algunas definiciones ...

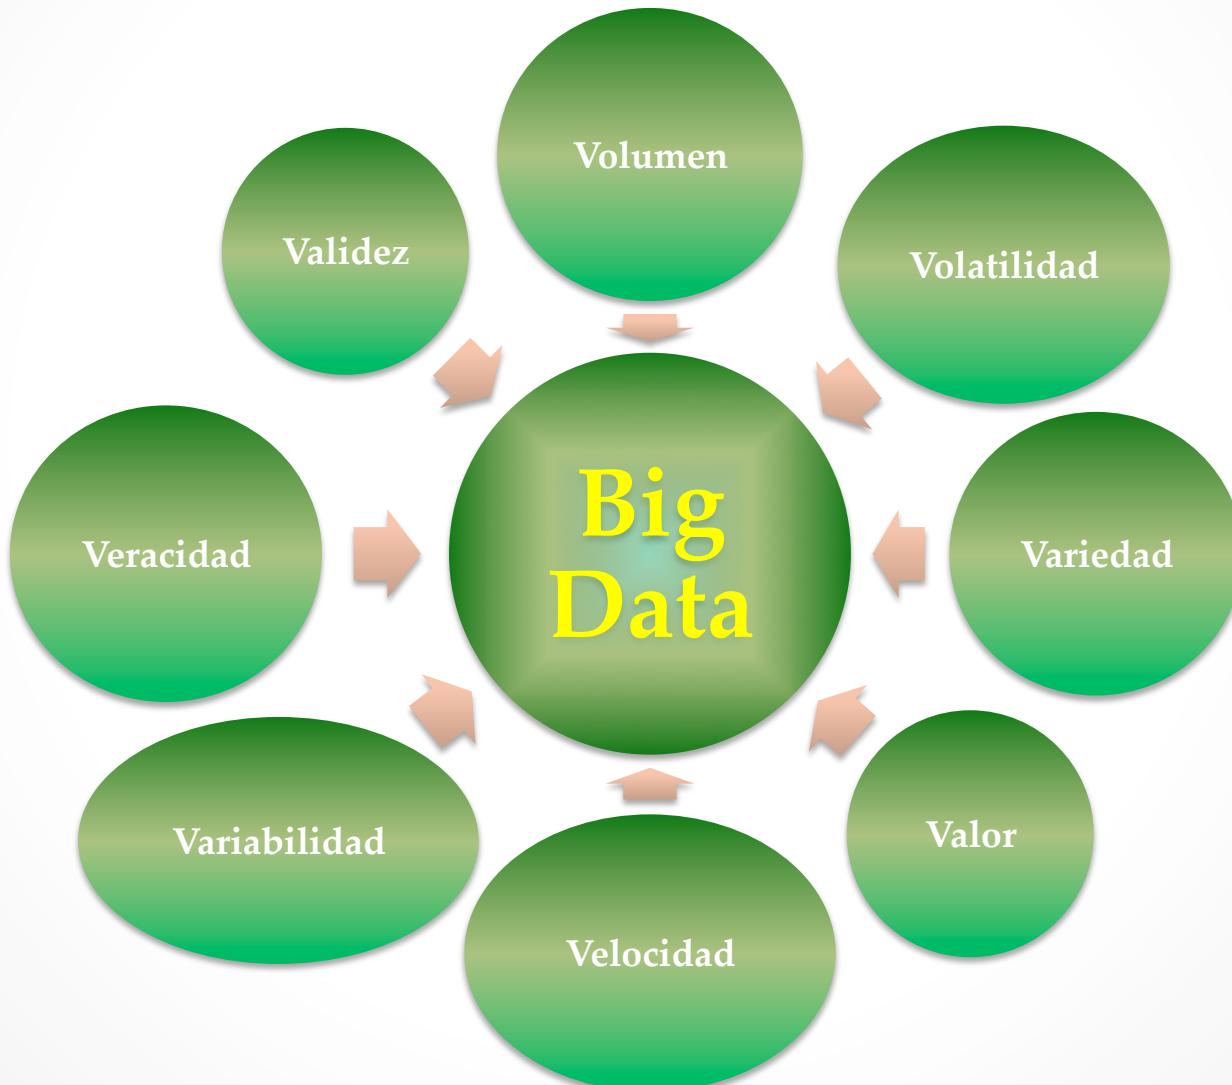
- “Big Data is the next generation of data warehousing and business analytics and is poised to deliver top line revenues cost efficiently for enterprises”
- “Big Data exceeds the reach of commonly used hardware environments and software tools to capture, manage, and process it within a tolerable elapse time for its user population”
- “Disciplina que se ocupa de todas las actividades relacionadas con los sistemas que manejan **grandes** conjuntos de datos, principalmente, almacenamiento, búsqueda, compartición, análisis y visualización”

# ¿Qué es Big Data?



Big data es cualquier característica sobre los datos que represente un reto para las capacidades de un sistema.

# Las 8 V's de Big Data



# Predicción de propagación de la gripe

*“Google puede predecir la propagación de la gripe (...) analizando lo que la gente busca en internet”*

**Más de 3.000M de búsquedas a diario**

- 50 M de términos de búsqueda más utilizados
- Google comparó esta lista con los datos de los CDC sobre propagación de gripe entre 2003 y 2008

J. Ginsberg, M.H. Mohebbi, R.S. Patel, L. Brammer, M.S. Smolinski, L. Brilliant.  
*Detecting influenza epidemics using search engine query data.*  
Nature 475 (2009) 1012-1014

- Encontraron una **combinación de 45 términos de búsqueda** que al usarse con un modelo matemático presentaba una correlación fuerte entre su predicción y las cifras oficiales de la enfermedad
- Podían decir, como los CDC, **a dónde se había propagado la gripe pero casi en tiempo real**, no una o dos semanas después,  
**con un método basado en Big Data**
- Se ha extendido a 29 países

- **En 2013 sobreestimó los niveles de gripe (x2 la estimación CDC)**
  - La sobreestimación puede deberse a la amplia cobertura mediática de la gripe que puede modificar comportamientos de búsqueda
  - Los modelos se van actualizando anualmente

BIG DATA

POLICYFORUM

**The Parable of Google Flu: Traps in Big Data Analysis**

Large errors in flu prediction were largely avoidable, which offers lessons for the use of big data.

David Lazer,<sup>1,2\*</sup> Ryan Kennedy,<sup>1,3\*</sup> Gary King,<sup>2</sup> Alessandro Vespignani,<sup>3,4</sup>



# Generadores de datos masivos



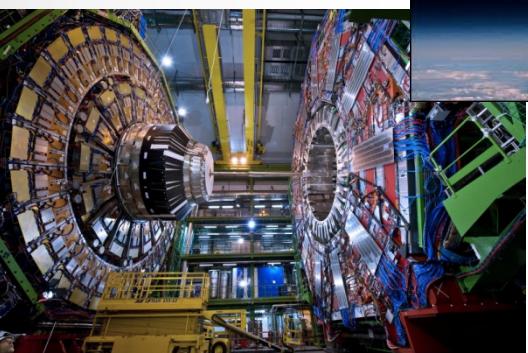
Redes sociales y multimedia



Transacciones



Dispositivos úbicos de generación de contenido



Redes de sensores

# ¿Cómo de “Big”?



# Ejemplo

## Evolutionary Computation for Big Data and Big Learning Workshop

### Big Data Competition 2014: Self-deployment track

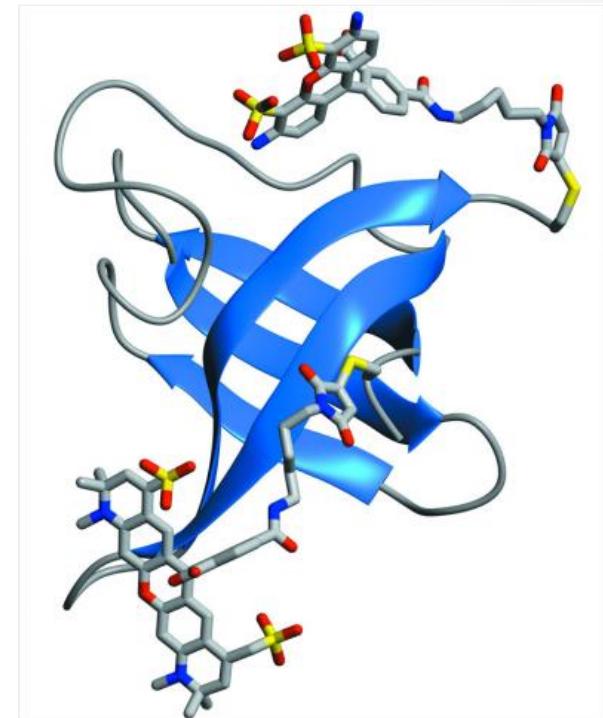
**Objective:** Contact map prediction

**Details:**

- 32 million instances
- 631 attributes (539 real & 92 nominal values)
- 2 classes
- 98% of negative examples
- About 56.7GB of disk space

**Evaluation:**

True positive rate · True negative rate  
TPR · TNR



- <http://cruncher.ncl.ac.uk/bdcomp/index.pl?action=data>



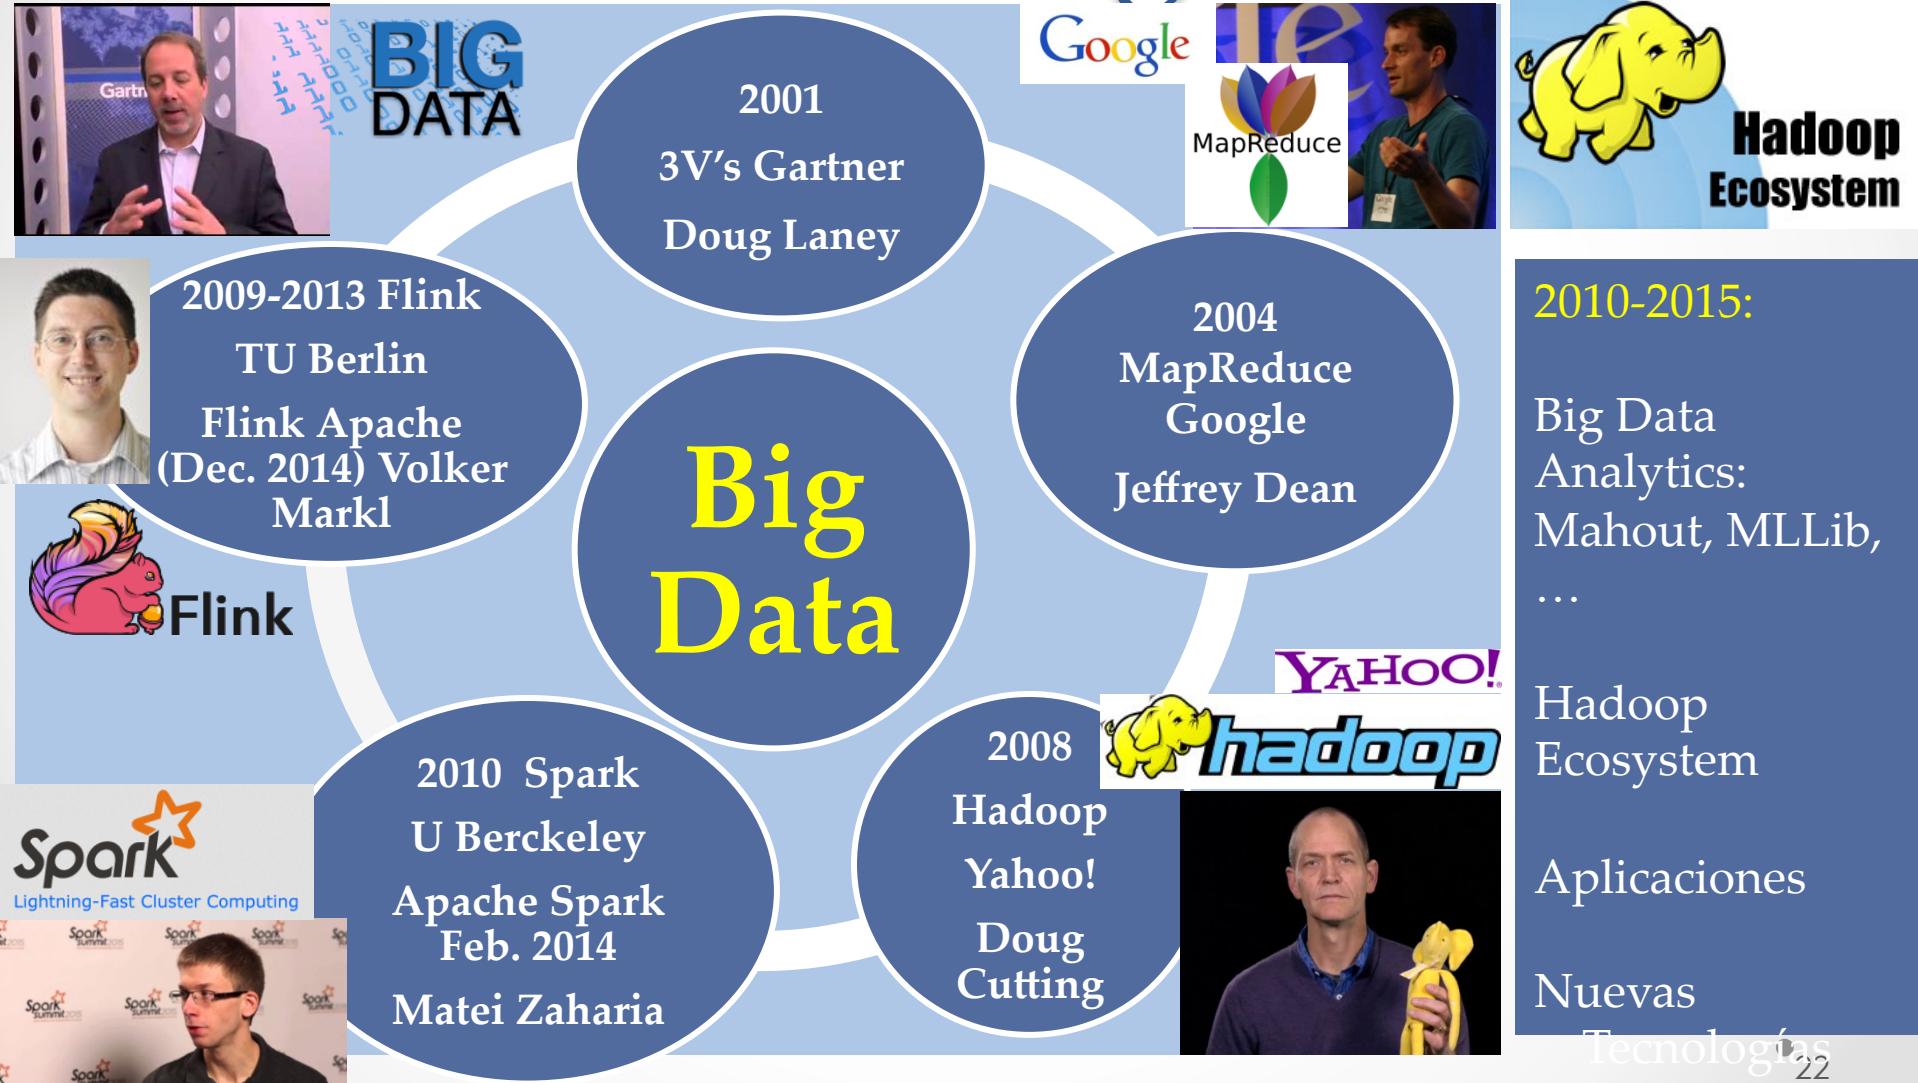
# Algoritmos en Big Data

Escalabilidad



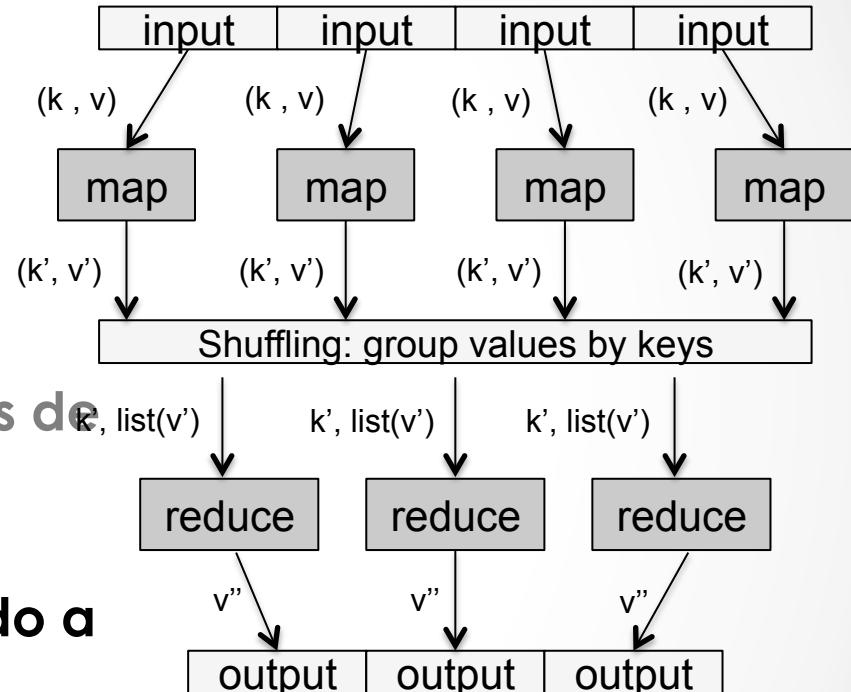
[www.echina-defense-mashup.com](http://www.echina-defense-mashup.com)

# Tecnología



# MapReduce

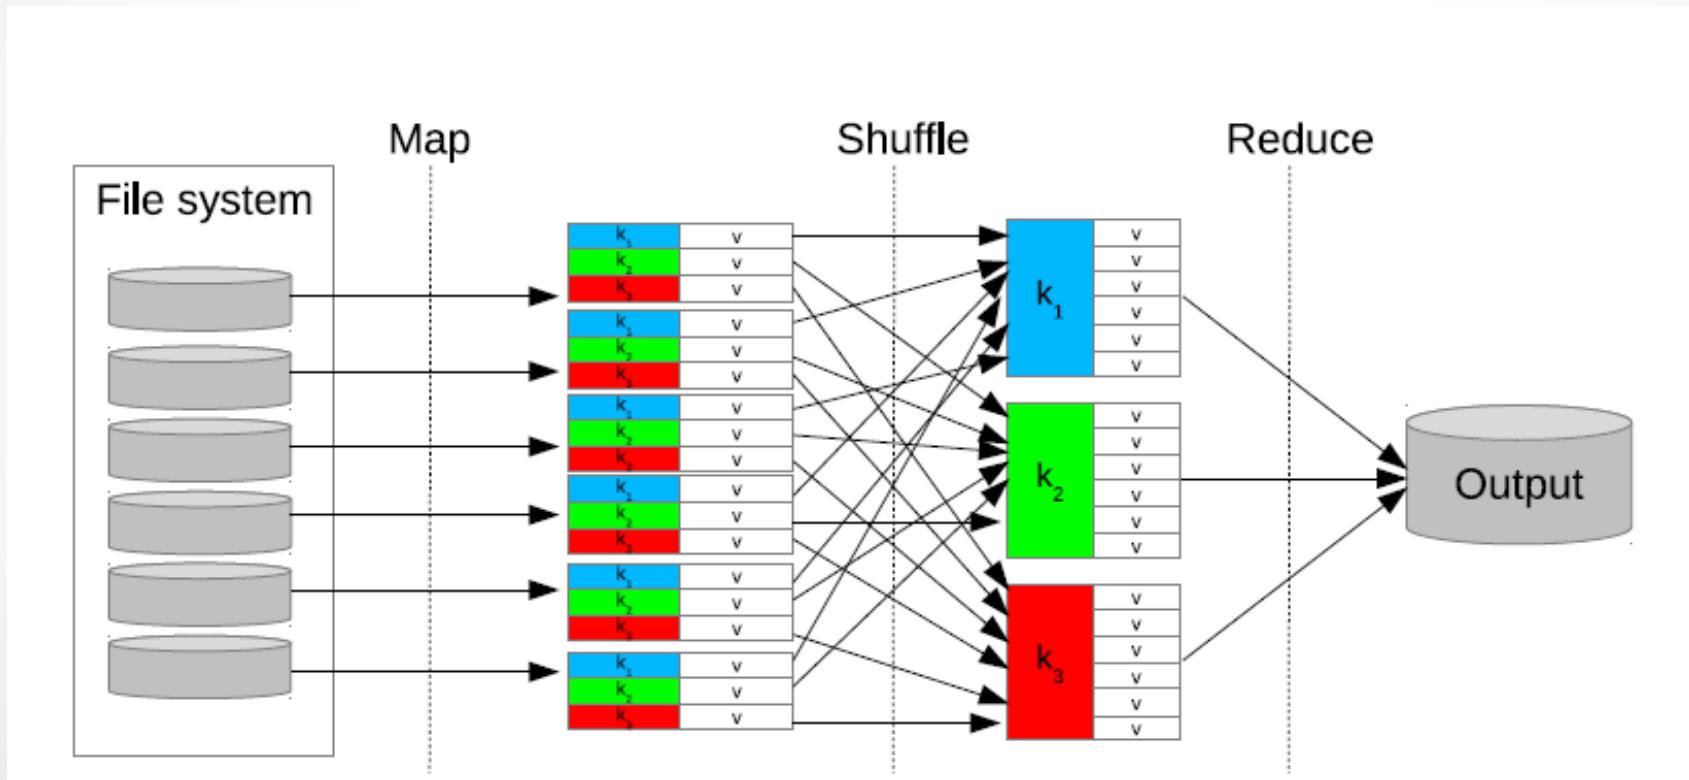
- MapReduce es el entorno más popular para Big Data
- Basado en la estructura {clave,valor}
- Dos operaciones:
  1. **Función Map:** Procesa bloques de información
  2. **Función Reduce:** Fusiona los resultados previous de acuerdo a su **clave**.
- + Una etapa intermedia de agrupamiento por clave (**Shuffling**)



map  $(k, v) \rightarrow list(k', v')$   
reduce  $(k', list(v')) \rightarrow v''$

# Flujo de datos

Flujo de datos es transparente para el programador



Ficheros de  
entrada

Ficheros Intermedios

Ficheros salida

# Características de MapReduce

- **Paralelización automática:**
  - Dependiendo del tamaño de ENTRADA DE DATOS → se crean múltiples tareas MAP
  - Dependiendo del número de intermedio <clave, valor> particiones → se crean tareas REDUCE
- **Escalabilidad:**
  - Funciona sobre cualquier cluster de nodos/procesadores
  - Puede trabajar desde 2 a 10.000 máquinas
- **Transparencia programación**
  - Manejo de los fallos de la máquina
  - Gestión de comunicación entre máquinas

# Resumiendo ...

- **Ventaja frente a los modelos distribuidos clásicos:**  
El modelo de programación paralela de datos de MapReduce oculta la complejidad de la distribución y tolerancia a fallos      *Programación distribuida para dummies*
- **Claves de su filosofía:** Es
  - **escalable:** se “olvidan” los *problemas de hardware*
  - **más barato:** se ahorran costes en *hardware, programación y administración*
- **MapReduce no es adecuado para todos los problemas, pero cuando funciona, puede ahorrar mucho tiempo**

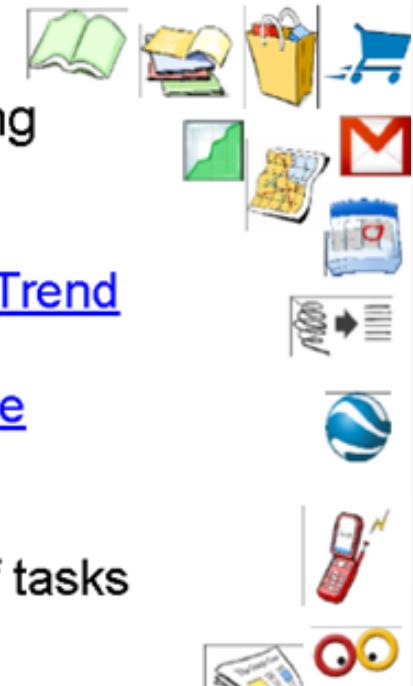
# Google Applications: más de 10.000 herramientas

## MapReduce inside Google



Googlers' hammer for 80% of our data crunching

- [Large-scale web search indexing](#)
- Clustering problems for [Google News](#)
- Produce reports for popular queries, e.g. [Google Trend](#)
- Processing of [satellite imagery data](#)
- Language model processing for [statistical machine translation](#)
- Large-scale [machine learning problems](#)
- Just a plain tool to reliably spawn large number of tasks
  - e.g. parallel data backup and restore



# Limitaciones de MapReduce

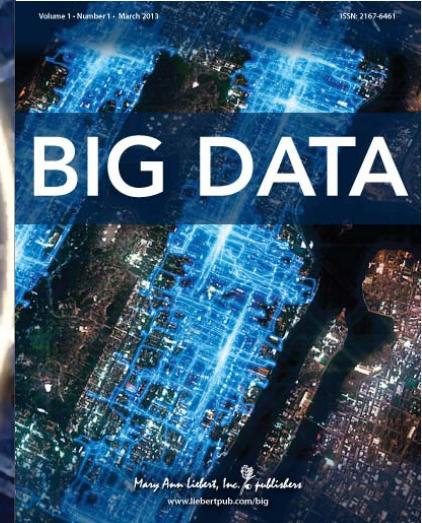
“If all you have is a hammer, then everything looks like a nail.”

MAPREDUCE  
IS GOOD  
ENOUGH?

If All You Have is a Hammer, Throw Away Everything That's Not a Nail!

Jimmy Lin

The iSchool, University of Maryland  
College Park, Maryland



Los siguientes tipos de algoritmos son ejemplos en los que MapReduce no funciona bien:

- Iterative Graph Algorithms: PageRank, ...
- Gradient Descent
- Expectation Maximization

# Hadoop



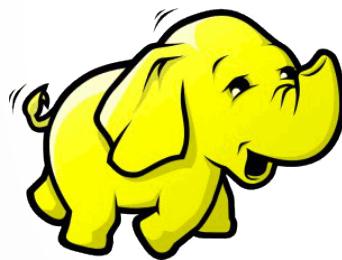
Hadoop es una implementación de código abierto del paradigma de programación MapReduce.

# Hadoop



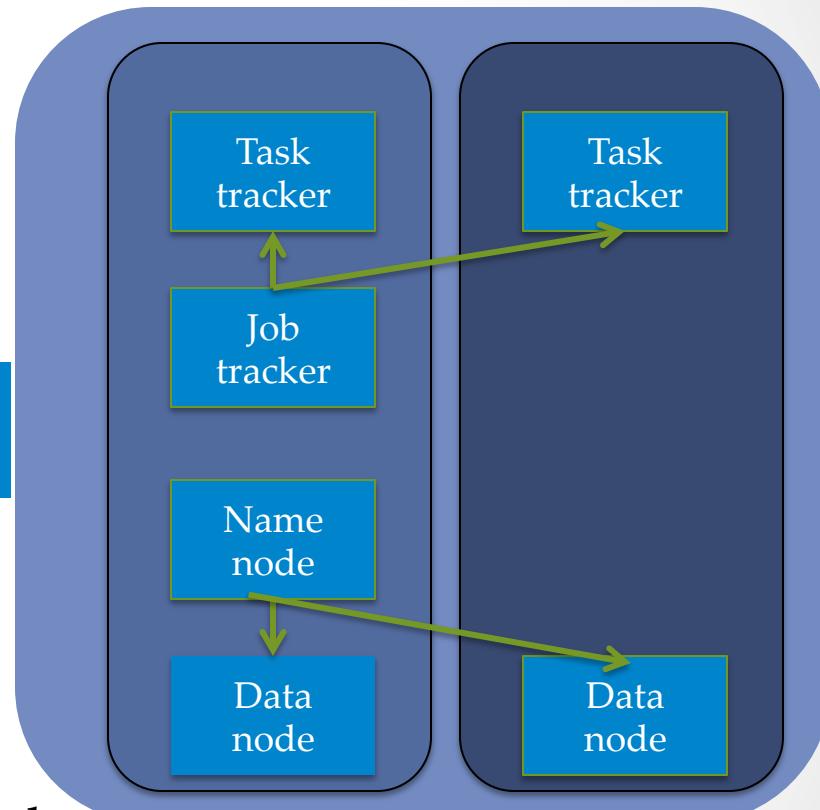
Escrito en java e inspirado en:

- MapReduce
- Google Distributed File System



Map Reduce  
Layer

HDFS  
Layer



Creado por **Doug Cutting** (chairman of board of directors of the Apache Software Foundation, 2010)



# Almacenamiento y procesamiento

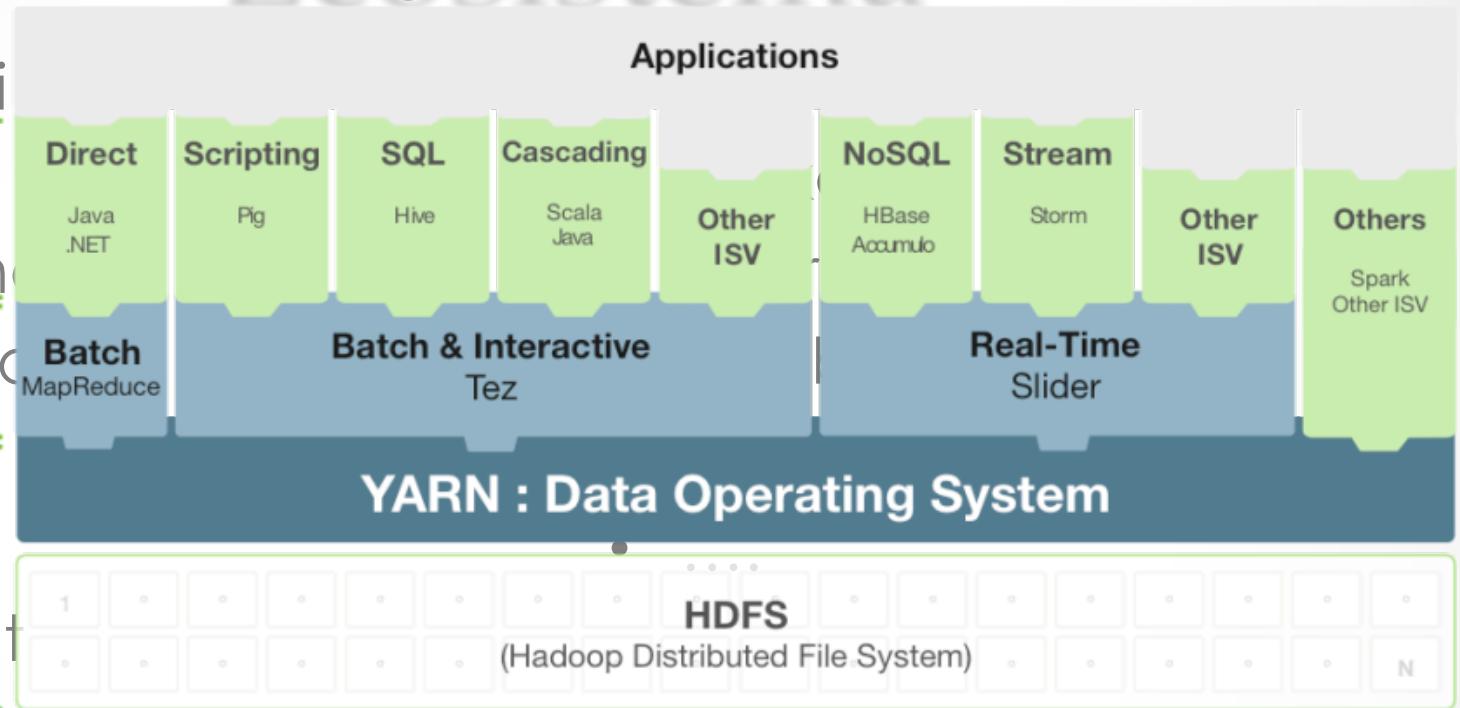
- Consta de dos servicios principales:
  - **Almacenamiento:** HDFS.
  - **Procesamiento:** MapReduce.



- Aporta una serie de ventajas:
  - **Bajo coste:** clústeres baratos / cloud.
  - **Facilidad de uso.**
  - **Tolerancia a fallos.**

# Ecosistema

- Ambari
- Avro API
- Cassandra
- Chukwa Engine
- Hbase
- Hive System
- Mahout
- Pig
- Tez
- ZooKeeper



# Spark

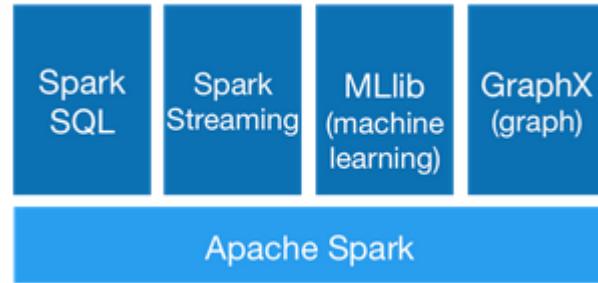


Entorno de trabajo (gestión de ejecución, API) genérico y rápido (hasta 100 veces más que Hadoop) para procesamiento de datos masivos

Centrado en una estructura de datos distribuida denominada “Resilient Distributed Dataset” (RDD)

Desarrollado en Scala. Interfaces en Scala, Java, Python, ...

# Spark

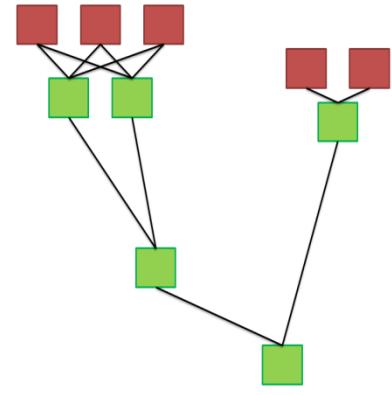


- **Big Data “in-memory”.** Spark permite realizar trabajos paralelizados totalmente en memoria:

Reducción de tiempos

Procesos iterativos

- **Esquema de computación más flexible que MapReduce.** Permite la flujo acíclicos de procesamiento de datos

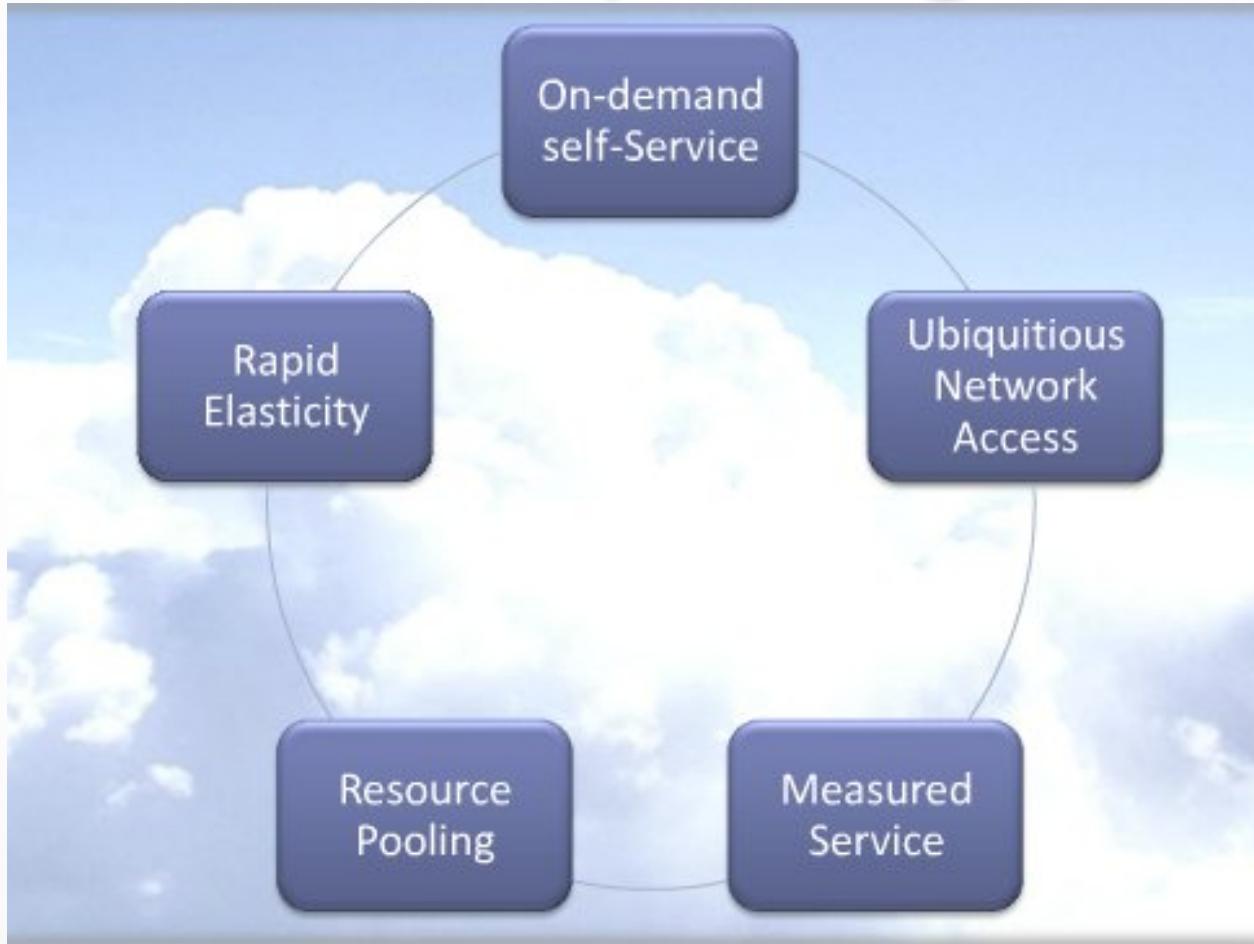


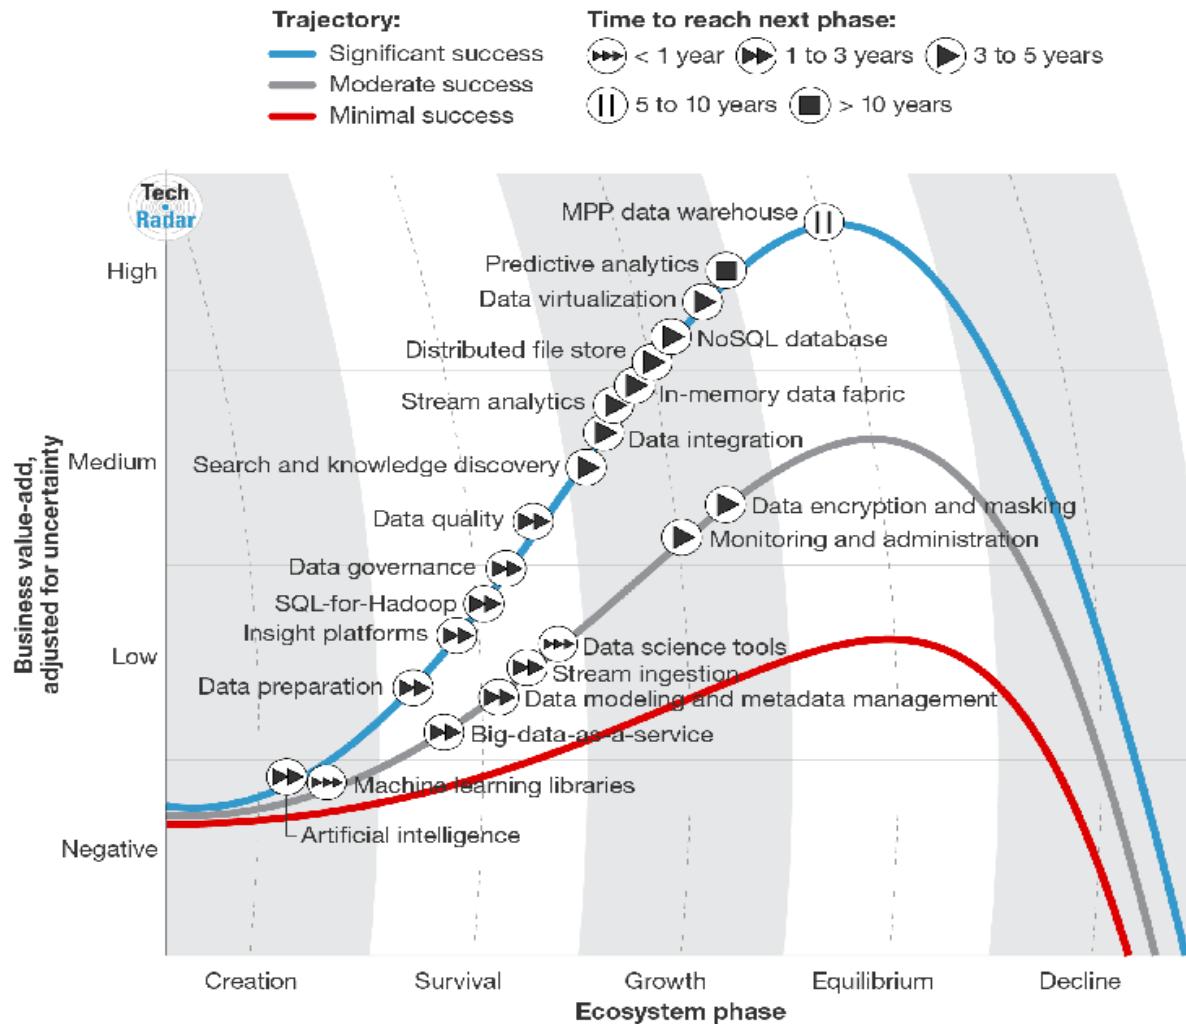


# Cloud Computing

- Modelo de **prestashopión de servicios** de negocio y tecnología, que permite al usuario acceder a un catálogo de servicios estandarizado y responder a las necesidades del negocio, de forma **flexible** y **adaptativa**, [...] **pagando** únicamente por **el consumo efectuado**.
- El usuario tiene la ilusión de estar utilizando un **ordenador virtual con recursos ilimitados**

# Aspectos claves de Cloud Computing



**TechRadar™: Big Data, Q1 '16***TechRadar™: Big Data, Q1 2016*

# WHERE IS DATA COMING FROM?

Facebook processes almost  
**350 GB** of data

Individuals and organizations launch  
**571** new websites

More than  
**100 million** new emails are generated

Twitter users send out  
**277,000** tweets

Google processes more than  
**2 million** search queries

**72 hours** of new video are uploaded to YouTube

**EVERY MINUTE...**

Walmart processes almost  
**17,000** transactions

Sprint processes more than  
**250,000** phone calls

# ¿Qué hacemos con estos datos?

- La tecnología hace salvables los obstáculos de recopilar y almacenar datos masivos, pero



Científico de datos

# Asociaciones en transacciones de tarjetas de crédito



# Asociaciones en datos de salud



Acción:  
Intervención  
después del alta  
Mejora salud mental  
y física



Expedientes médicos varias años  
Para reducir la tasa de reingresos



aflicción mental como  
“depresión”  
aumentaban los  
reingresos en 1 mes

# Sistemas de recomendación



Los datos incrementaron tremadamente las ventas  
Ahora más de 1/3 de las ventas son gracias a las recomendaciones

Críticos y editores literarios  
La voz de Amazon (1995)



Dilema: ¿Lo que los clics decían o lo que opinaban los críticos?



Greg Linde (1997) propuso un sistema de recomendaciones filtrado colaborativo “artículo a artículo”



# Un chivo expiatorio



Disculpas Empresa.  
Disculpas del padre,  
confirmación del  
embarazo de la hija

Modelo de predicción  
de clientes embarazadas  
por medio de sus  
patrones de compra.



Enfado de un padre: Su  
Hija recibe publicidad de  
productos para  
embarazadas



Acción: Envío de  
cupones para cada  
fase del embarazo

Descubrimiento:  
Cremas sin perfume al  
tercer mes. Dos docenas  
de productos  
Predicción de fecha parto

# Un chivo expiatorio ...

Target (cadena de grandes almacenes) que utiliza el análisis de transacciones y asociaciones.

**Unos días después el director llamó al hombre** para disculparse. Respuesta conciliadora: “**He estado hablando con mi hija** –dijo el hombre – **Resulta que en mi casa han tenido lugar ciertas actividades de las que yo no estaba del todo informado. Mi hija sale de cuentas en agosto. Soy yo el que les debe una disculpa**”.



# Impacto económico

La demanda de profesionales formados en Ciencia de Datos y *Big Data* es enorme.

Se estima que la conversión de datos en información útil generará un mercado de 132.000 millones de dólares en 2015 y que se crearán más de 4.4 millones de empleos.

España necesitará para 2015 más de 60.000 profesionales con formación en Ciencia de Datos y *Big Data*.

España necesitará 60.000 profesionales de Big Data hasta 2015

The screenshot shows a news article from EL PAÍS ECONOMÍA. The headline reads "España necesitará 60.000 profesionales de Big Data hasta 2015". Below the headline is a photograph of a man giving a presentation to an audience. The text below the photo states "España necesitará 60.000 profesionales de Big Data hasta 2015". The article is dated 22 octubre, 2013. The EL PAÍS logo is at the top right, along with links to PORTADA, INTERNACIONAL, and POLÍTICA. The main menu includes ECONOMÍA, EMPRESAS, MERCADOS, BOLSA, FINANZAS PERSONALES, VIVIENDA, TECNOLOGÍA, ESTÁ PASANDO, Multa a la banca, Revuelto en Hacienda, Eléctricas y renovables, and Paro.

## El maná de los datos

■ La conversión de datos en información útil para las empresas generará un mercado de 132.000 millones de dólares en 2015. La herramienta 'big data' sacará del mercado a quien no la use

SUSANA BLÁZQUEZ | Madrid | 29 SEP 2013 - 01:00 CET

10

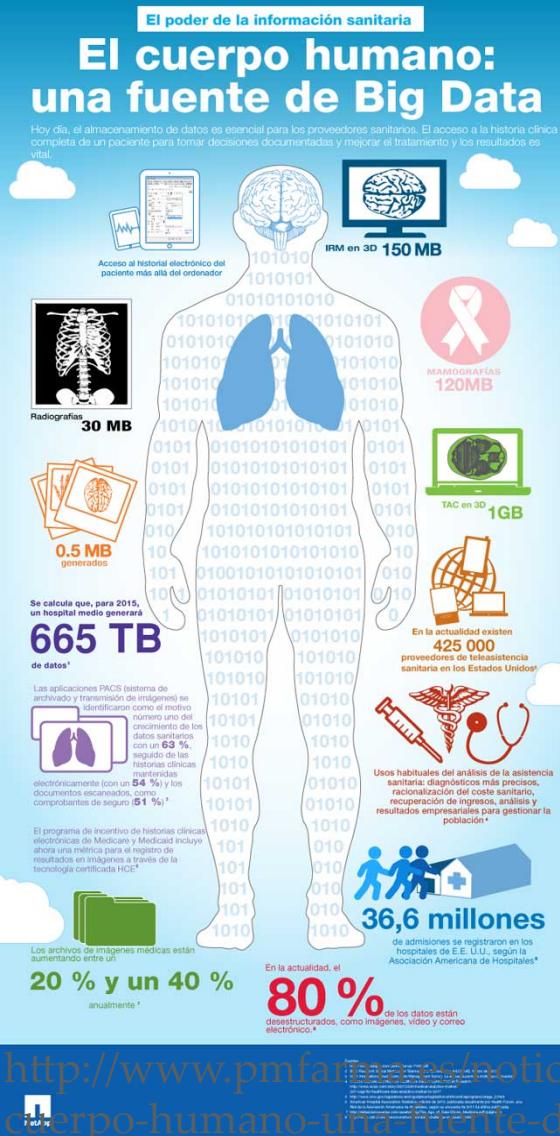
Archivado en: Citigroup Cap Gemini Sogeti SAP Oracle ING Bank BBVA Mapfre Bases datos IBM Telefónica Aplicaciones informáticas Tecnología Empresas Programas informáticos Economía



[http://economia.elpais.com/economia/2013/09/27/actualidad/1380283725\\_938376.html](http://economia.elpais.com/economia/2013/09/27/actualidad/1380283725_938376.html)

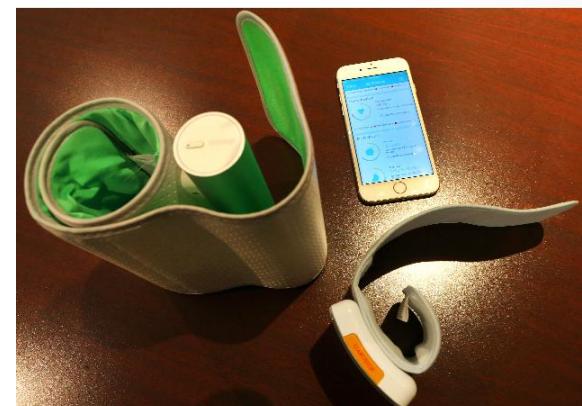
# Cuidando la Salud

Las organizaciones de salud han coleccionado en los últimos años exabytes de información



Big data puede facilitar acciones para modificar los factores de riesgo que contribuyen a un porcentaje grande de las enfermedades crónicas, tales como actividad física, dieta, tabaco, exposición a la polución ...

## Móviles y Big data, una buena alianza: Sensores y aplicaciones en el móvil



*Wearable blood pressure monitors send data to a smartphone app, then off to the doctor. (Photo by John Tlumacki/The Boston Globe via Getty Images)*

# Analizando Twitter para medir la Salud Pública

*You Are What You Tweet*

Un sistema de filtrado de datos de Twitter puede inferir aspectos de salud analizando 144M de tuits (2011-2013)



Se obtienen 13 grupos coherentes de mensajes correlacionados

- Gripe estacional ( $r= 0.689$ ) y alergias ( $r = 0.810$ )
- Ejercicio y obesidad relacionados con datos geográficos, ..

Discovering Health Topics in Social Media Using Topic Models

Michael J. Paul, Mark Dredze, Johns Hopkins University, Plos

47

# Banca: Análisis de datos

Expansión.com

Domingo, 08.12.13. Actualizado a las 11:02

## BBVA da un paso al frente en 'big data'

El banco ha actualizado todo su sistema de almacenamiento de datos corporativo para tener acceso desde un único punto a todas las 'islas de información' de la entidad en el mundo y consolidarse como un referente mundial en innovación tecnológica.



BBVA  
Innova Challenge API  
Available statistics services

Tendencias de negocio:  
Análisis de compras con  
tarjetas de crédito ...



# Banca: Identificación de personas con las compras de tarjetas de crédito

[http://elpais.com/elpais/2015/01/29/ciencia/1422520042\\_066660.html](http://elpais.com/elpais/2015/01/29/ciencia/1422520042_066660.html)

PRIVACIDAD EN INTERNET »

## Cuatro compras con la tarjeta bastan para identificar a cualquier persona

- Los patrones de uso de las tarjetas permiten descubrir la identidad del 90% de una muestra de 1,1 millones de personas anónimas, según demuestra un estudio del MIT



## Unique in the shopping mall: On the reidentifiability of credit card metadata

Yves-Alexandre de Montjoye,<sup>1,\*</sup> Laura Radaelli,<sup>2</sup> Vivek Kumar Singh,<sup>1,3</sup> Alex “Sandy” Pentland<sup>1</sup>

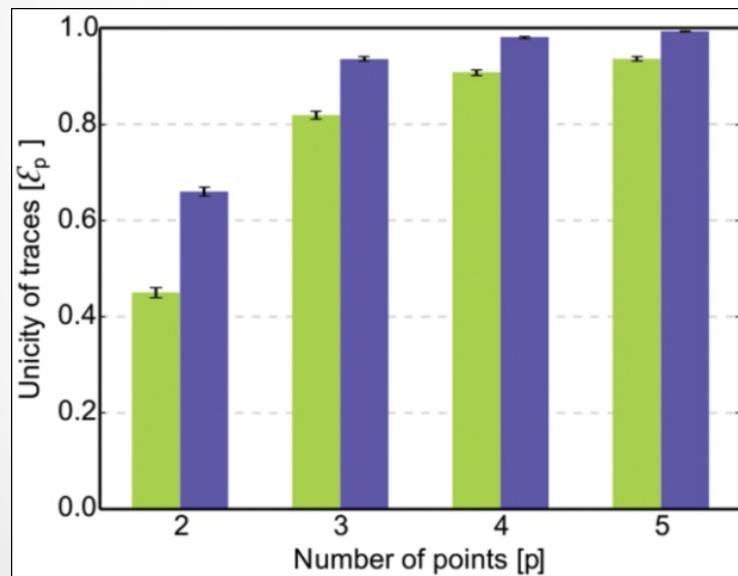
Large-scale data sets of human behavior have the potential to fundamentally transform the way we fight diseases, design cities, or perform research. Metadata, however, contain sensitive information. Understanding the privacy of these data sets is key to their broad use and, ultimately, their impact. We study 3 months of credit card records for 1.1 million people and show that four spatiotemporal points are enough to uniquely reidentify 90% of individuals. We show that knowing the price of a transaction increases the risk of reidentification by 22%, on average. Finally, we show that even data sets that provide coarse information at any or all of the dimensions provide little anonymity and that women are more reidentifiable than men in credit card metadata.

# Banca: Identificación de personas con las compras de tarjetas de crédito

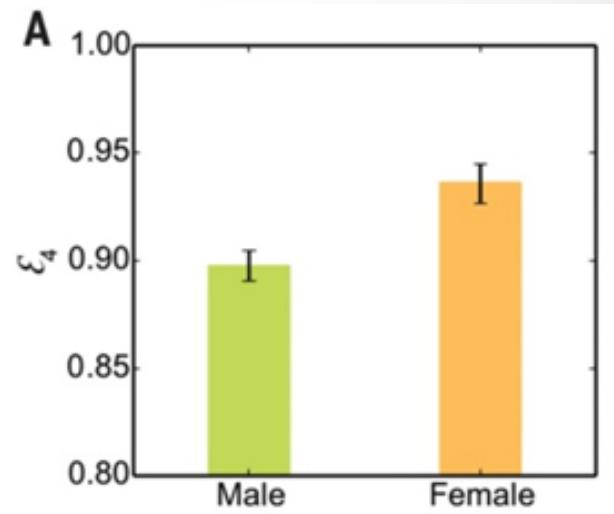
PRIVACIDAD EN INTERNET »

## Cuatro compras con la tarjeta bastan para identificar a cualquier persona

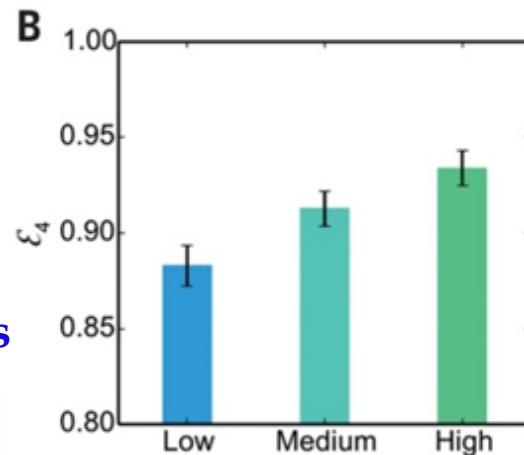
- Los patrones de uso de las tarjetas permiten descubrir la identidad del 90% de una muestra de 1,1 millones de personas anónimas, según demuestra un estudio del MIT



Identificación por el número de compras



Identificación por el género



Identificación por el poder adquisitivo

# Industria. Automoción

EL PAÍS

## COCHES SIN CONDUCTOR

### Un coche autónomo recorre por primera vez las carreteras de España

- Un prototipo cubre la distancia entre Vigo y Madrid, apenas una semana después la DGT cambiara la normativa para permitir estos ensayos
- [¿Llega la hora del vehículo conectado?](#)

J. J. GÁLVEZ | Madrid | 23 NOV 2015 - 18:49 CET



Archivado en: DGT Citroën Coches sin conductor Direcciones Generales Grú  
Nuevas tecnologías Coches Ministerios Vehículos Fabricantes automóviles



Interior del vehículo autónomo que ha salido este lunes a la carretera. / EFE (PROMOCIONAL)

PILOTO AUTOMÁTICO »

### Conduce si te apetece

- El piloto automático está cada vez más cerca, aunque la tecnología llegará por fases
- [El piloto automático ya es obligatorio en las autopistas y autovías europeas](#)
- [El de ciudad](#)
- [El de Nissan](#)

GOOGLE CAR »

### Con flores y sin volante

- La artista española Inmaculada del Castillo gana el concurso para decorar el coche sin conductor de Google
- [El accidentado estreno del coche sin conductor de Google](#)

ROSA JIMÉNEZ CANO | San Francisco | 20 OCT 2015 - 11:52 CEST



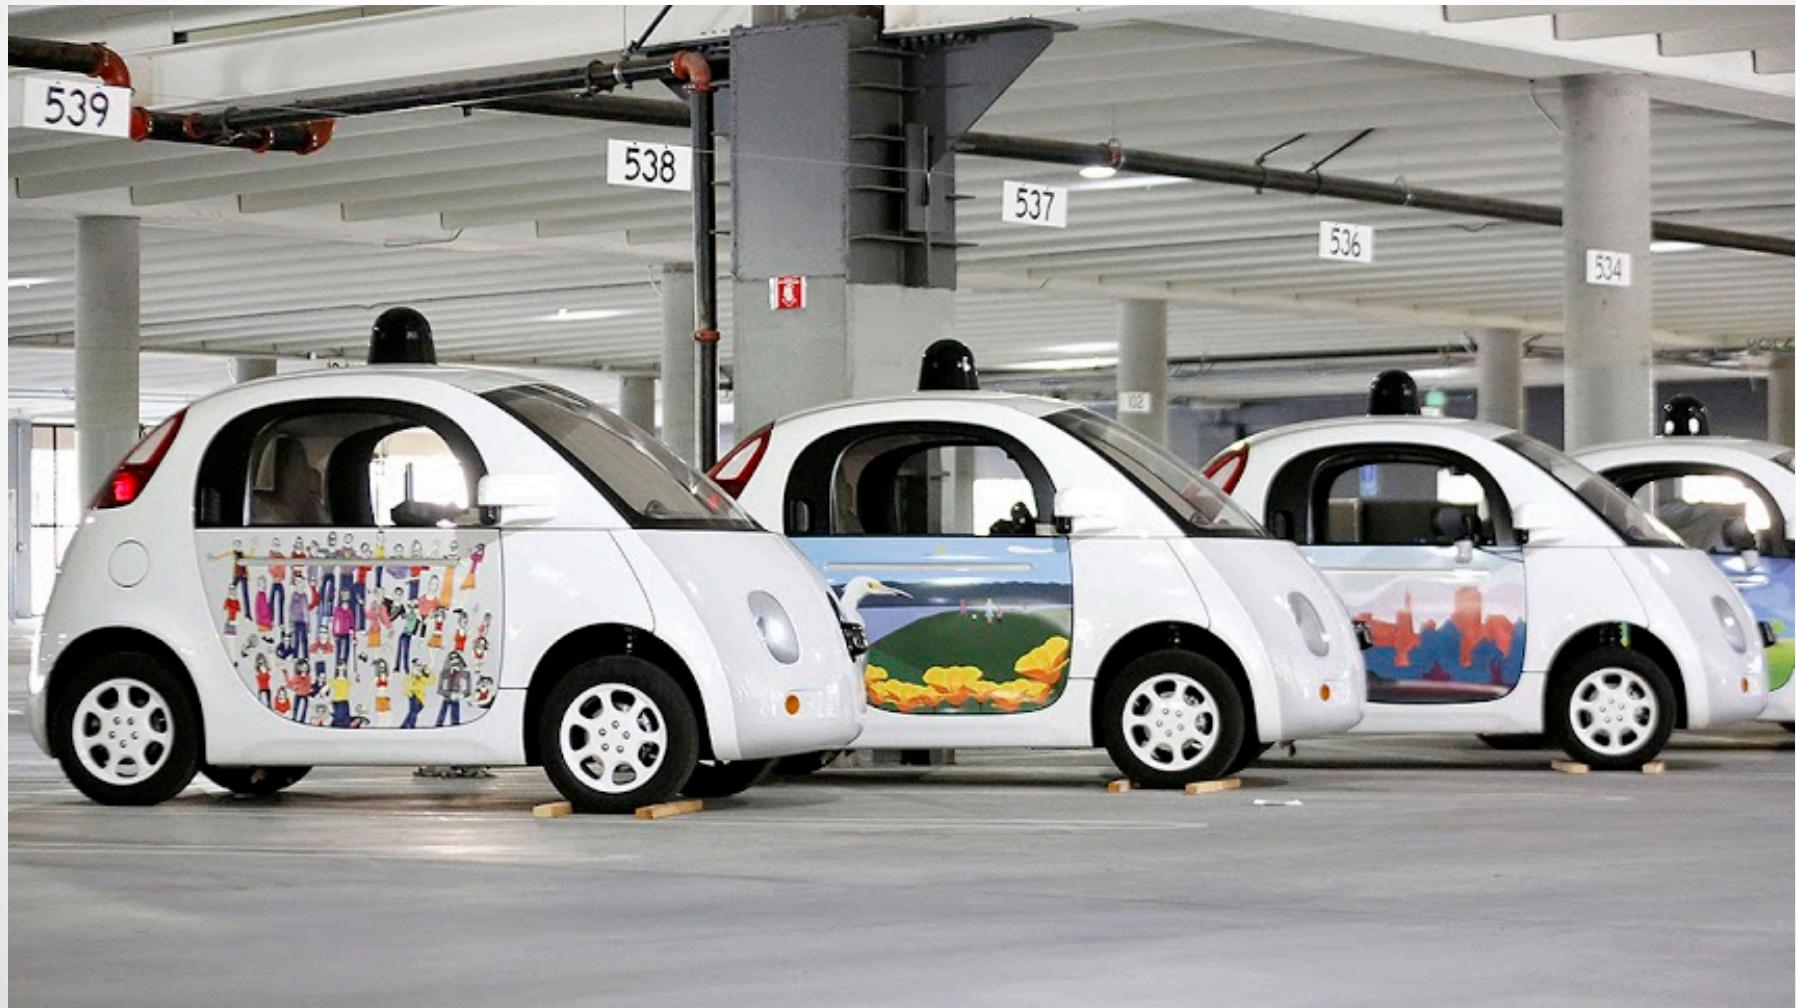
Archivado en: Silicon Valley Tesla Motors Google car San Francisco Coches sin conductor Google California Nuevas tecnologías Buscadores Alphabet Estados Unidos Coches



La artista Inmaculada del Castillo posa junto al coche sin conductor de Google y su diseño. / DAVID DITZEL (EL PAÍS)



# Industria. Automoción

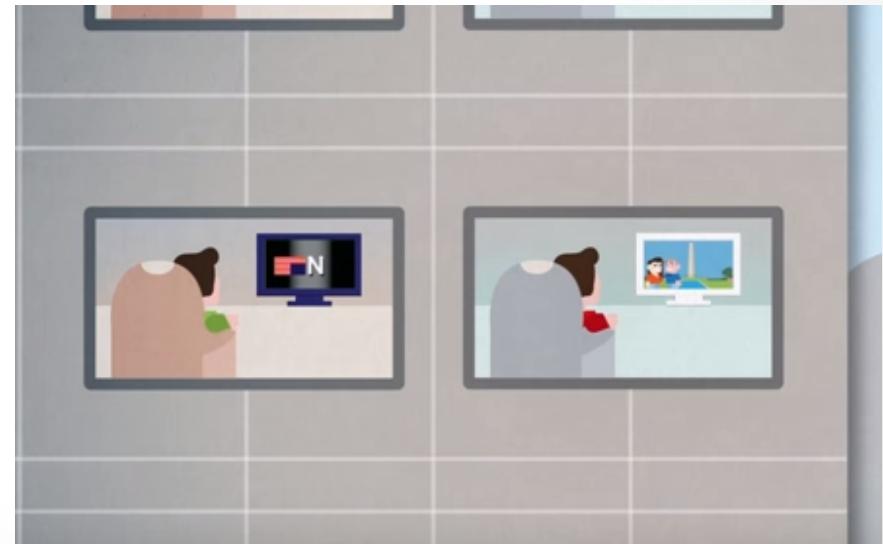


# Netflix: Sistema de recomendación



Para Netflix, compañía de alquiler de películas online, las tres cuartas partes de los pedidos nuevos surgen de las recomendaciones.

Netflix y Amazon son dos empresas cuyo plan de negocio está basada en big data y sistemas de recomendación



# Big Data para el Bien Social



## UNITED NATIONS GLOBAL PULSE

Harnessing big data for development and humanitarian action

### GLOBAL PULSE PROJECT SERIES

The Global Pulse Project Series is a collection of case studies of 20 data innovation projects covering global issues ranging from public health to climate change, food security to employment.

[Read More /](#)

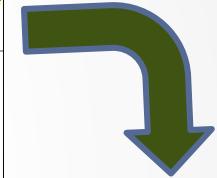
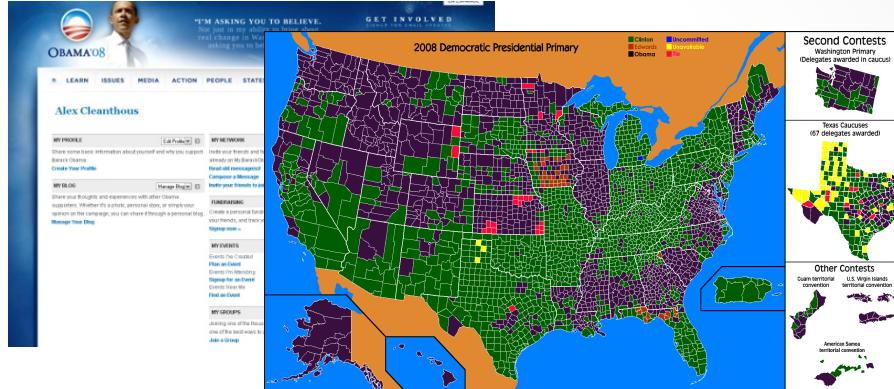
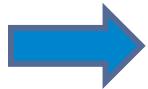


### Global Pulse Project Series



El análisis de datos también debe servir para mejoras sociales y avances en la sociedad

# Big Data en la Política



26 Septiembre, 1960

**6.845** mensajes **79** conversaciones

**3** partidos



Campaña elecciones autonómicas  
y municipales de 2015



Número de seguidores en Facebook

1.000.000  
**978.502**

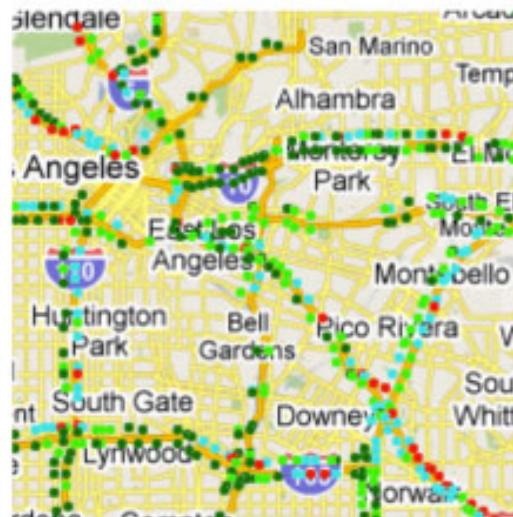
“Se puede describir el modelo de acción de los principales partidos políticos en España en sitios de interacción social determinando el comportamiento en su acción comunicativa a través de métodos de recuperación de información y ciencia datos.”

100.000





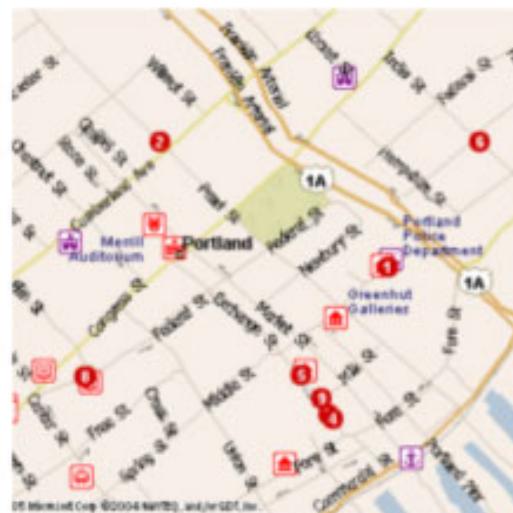
1. Moving objects



2. Traffic sensor data



3. Road network data



4. Points-of-interest data

# Conclusiones

- Existe el Big Data
- Resuelve problemas **reales**
- No todo es Big Data
- La tecnología está en desarrollo

Las grandes colecciones de datos nos  
conducen continuamente a innovaciones (en  
la industria, ciencia, sociedad)